# ▼ TOP MUSIC HITS - Proiect Big Data

Scopul acestui proiect este de a incerca prezicerea popularitatii unor cantece in functie de caracteristicile acestora. Acesta poate fi folosit pentru analizarea datelor si oferirea de recomandari artistilor interesati sa produca un nou hit. De asemenea, inaintea incercarii prezicerii popularitatii, setul de date va fi analizat pe cateva caractaeristici pentru a vedea ce preferinte muzicale ajuta un cantec sa ajunga in top.

Setul de date se numește songs\_normalize și conține 18 coloane si 2000 de intrari reprezentand hiturile din anii 2000 - 2019 de pe platforma Spotify. Pentru o mai buna intelegere a setului de date voi prezenta coloanele si semnificatiile acestora mai jos:

- artist: numele artistului
- song: numele piesei
- duration\_ms: durata piesei in milisecunde
- **explicit**: versurile sau continutul unui cantec contin unul sau mai multe cuvinte/secvente care ar putea fi considerate jignitoare sau nepotrivite pentru copii
- year: anul lansarii piesei.
- popularity: cu cat valoarea este mai mare, cu atat melodia este mai populara
- danceability: descrie cat de potrivita este o piesa pentru dans, pe baza unei combinatii de elemente muzicale, inclusiv tempo, stabilitatea ritmului, puterea ritmului si regularitatea generala, unde valoarea de 0,0 este cea mai putin dansabila si 1,0 este cea mai dansabila
- energy: o valoare intre 0,0 si 1,0 ce reprezinta o masura perceptiva a intensitatii si a activitatii
- **key**: cheia in care se afla melodia. Se mapeaza folosind notatia standard Pitch Class. De exemplu: 0 = C, 1 = C♯/D♭, 2 = D etc. Daca nu a fost detectata nicio cheie, valoarea este -1
- **loudness**: volumul total al unei piese în decibeli (db). Valorile sonore sunt mediate pe durat intregii piese si sunt utile pentru a compara intensitatea relativa a acestora. Valorile variaza de obicei intre -60 și 0 db.
- **mode**: indica modalitatea (major sau minor) a unei piese. Major este reprezentat de 1 si minor este 0.
- speechiness: detectează prezenta cuvintelor rostite intr-o piesa. Cu cat inregistrarea are
  mai multe cuvinte (exemplu: talk-show, carte audio), cu atat valoarea atributului este mai
  aproape de 1.0. Valorile de peste 0,66 descriu piese care sunt probabil formate in
  intregime din cuvinte. Valorile intre 0,33 și 0,66 descriu piese care pot conține muzica dar
  si vorbire, inclusiv cazuri precum muzica rap. Valorile sub 0,33 reprezintă cel mai probabil
  muzica si alte melodii care nu contin cuvinte
- acousticness: are valori de la 0.0 la 1.0, unde 1.0 reprezintă o incredere ridicată ca pista este acustica

- **instrumentalness**: prezice daca o piesa nu contine voce. Sunetele "Ooh" si "aah" sunt tratate ca instrumentale in acest context. Melodiile rap sau vorbite sunt în mod clar "vocale". 1.0 indica cea mai mare probabilitatea ca piesa sa nu contina cuvinte (valorile de peste 0.5 sunt menite sa indice piese instrumentale, dar siguranta creste cand valoarea se apropie de 1.0)
- liveness: detectează prezenta unei audiente. O valoare peste 0.8 indica o probabilitate mare ca piesa sa fie live
- valence: o valoare de la 0.0 la 1.0 care descrie pozitivitatea muzicala transmisa de o piesa. Piesele cu valenta ridicata suna mai pozitiv (fericit, vesel, euforic), in timp ce piesele cu valenta scazuta suna mai negativ (trist, deprimat, furios)
- **tempo**: tempo-ul total estimat al unei piese in batai pe minut (BPM).
- **genre**: genul piesei

## Etapele proiectului:

- 1. Importarea librariilor si creearea sesiunii spark
- 2. Importarea setului de date din fisierul CSV aflat in Google Drive
- 3. Prezentarea datelor (coloane, numar de intrari, cateva statistici)
- 4. Verificarea, prelucrarea si pregatirea datelor
  - Verificarea pe coloane a existentei valorilor null
  - Verificarea datelor din coloana 'genre'
  - o Transformarea variabilei 'genre' de tip string in variabila categoriala
  - Creearea unui vector de 'features' folosind VectorAssembler
- 5. Selectia modelelor:
  - Linear Regression
  - Random Forest + creearea si utilizarea unui pipeline
  - Gradient-boosted tree regression + creearea si utilizarea unui pipeline
- 6. Utilizarea unui model DL utilizand Tensorflow
- ▼ 1. Importarea librariilor si creearea sesiunii spark

```
Stored in directory: /root/.cache/pip/wheels/7a/8e/1b/f73a52650d2e5f337708d9f6a175@
Successfully built pyspark
Installing collected packages: py4j, pyspark
Successfully installed py4j-0.10.9.5 pyspark-3.3.0
```

# Se importa librariile ce vor fi folosite in proiect from google.colab import drive import numpy as np import matplotlib.pyplot as plt import seaborn as sns from pyspark.sql import functions import pyspark.sql.functions as f from pyspark.sql.functions import col from pyspark.ml.feature import VectorAssembler, VectorIndexer, OneHotEncoder, StringIndexer from pyspark.ml.linalg import Vectors from pyspark.ml import Pipeline from pyspark.ml.regression import LinearRegression, RandomForestRegressor, GBTRegressor from pyspark.ml.evaluation import RegressionEvaluator from sklearn.model\_selection import train\_test\_split from sklearn.preprocessing import MinMaxScaler from tensorflow.keras.models import Sequential from tensorflow.keras.layers import Dense from sklearn.metrics import mean\_squared\_error, mean\_absolute\_error, mean\_squared\_log\_erro # Se creeaza o sesiune spark: "music hits" from pyspark.sql import SparkSession

## 2. Importarea setului de date din fisierul CSV aflat in Google Drive

spark = SparkSession.builder.appName('music\_hits').getOrCreate()

## ▼ 3.Prezentarea datelor

Se vor afisa: schema datelor, numarul de intrari din setul de date, coloanele existente, afisarea primelor 20 de intrari, o statistica si cateva ploturi (matricea de corelatii si histograme). Primul plot va fi reprezentat de matricea de corelatii si va contine toate atributele din setul de date, al doilea plot va fi o histograma ce va prezenta distributia variabilei 'popularity' iar al treilea plot va fi o histograma ce va analiza variabila 'valenta'.

# Se afiseaza schema datelor

```
6/22/22, 12:13 AM
    df.printSchema()
          root
```

```
|-- artist: string (nullable = true)
      |-- song: string (nullable = true)
      |-- duration_ms: integer (nullable = true)
      |-- explicit: boolean (nullable = true)
      |-- year: integer (nullable = true)
      |-- popularity: integer (nullable = true)
      |-- danceability: double (nullable = true)
      |-- energy: double (nullable = true)
      |-- key: integer (nullable = true)
      |-- loudness: double (nullable = true)
      |-- mode: integer (nullable = true)
      |-- speechiness: double (nullable = true)
      |-- acousticness: double (nullable = true)
      |-- instrumentalness: double (nullable = true)
      |-- liveness: double (nullable = true)
      |-- valence: double (nullable = true)
      |-- tempo: double (nullable = true)
      |-- genre: string (nullable = true)
# Se afiseaza numarul de intrari din setul de date
df.count()
     2000
# Se afiseaza coloanele din setul de date
df.columns
     ['artist',
      'song',
      'duration_ms',
      'explicit',
      'year',
      'popularity',
      'danceability',
      'energy',
      'key',
      'loudness',
      'mode',
      'speechiness',
      'acousticness',
      'instrumentalness',
      'liveness',
      'valence',
      'tempo',
      'genre']
```

# Se afiseaza datele (primele 20 de randuri) df.show()

> artist| song|duration\_ms|explicit|year|popularity|danceabili | Britney Spears | Oops!...I Did It ... | 211160 | false | 2000 | 77 0.7

blink-182	All The Small Things	167066	false 1999	79	0.4
Faith Hill	Breathe	250546	false 1999	66	0.5
Bon Jovi	It's My Life	224493	false 2000	78	9.5
*NSYNC	Bye Bye Bye	200560	false 2000	65	0.6
Sisqo	Thong Song	253733	true 1999	69	0.7
Eminem	The Real Slim Shady	284200	true 2000	86	0.9
Robbie Williams	Rock DJ	258560	false 2000	68	0.7
Destiny's Child	Say My Name	271333	false 1999	75	0.7
Modjo	Lady - Hear Me To	307153	false 2001	77	0
Gigi D'Agostino	L'Amour Toujours	238759	false 2011	1	0.6
Eiffel 65	Move Your Body	268863	false 1999	56	0.7
Bomfunk MC's	Freestyler	306333	false 2000	55	0.8
Sting	Desert Rose	285960	false 1999	62	0.5
Melanie C	Never Be The Same	294200	false 1999	61	0.6
Aaliyah	Try Again	284000	false 2002	53	0.7
Anastacia	I'm Outta Love	245400	false 1999	64	0.7
Alice Deejay	Better Off Alone	214883	false 2000	73	0.6
Gigi D'Agostino	The Riddle	285426	false 1999	64	0
Dr. Dre	The Next Episode	161506	true 1999	82	0.9
+			+	+	<b></b>

only showing top 20 rows



# Se va afisa o scurta statistica asupra setului de date
df.summary().show()

	summary	artist	song	duration_ms	year	
	count					
	mean	'				•
 	stddev   min		"CAN'T STOP THE F	39136.569007525984   113000		•
i	25%					
	50%	112.0	1955.0	223266	2010	
	75%	112.0	2002.0	248133	2015	
	max	will.i.am	Échame La Culpa	484146	2020	
+	+			h		<b>}</b>

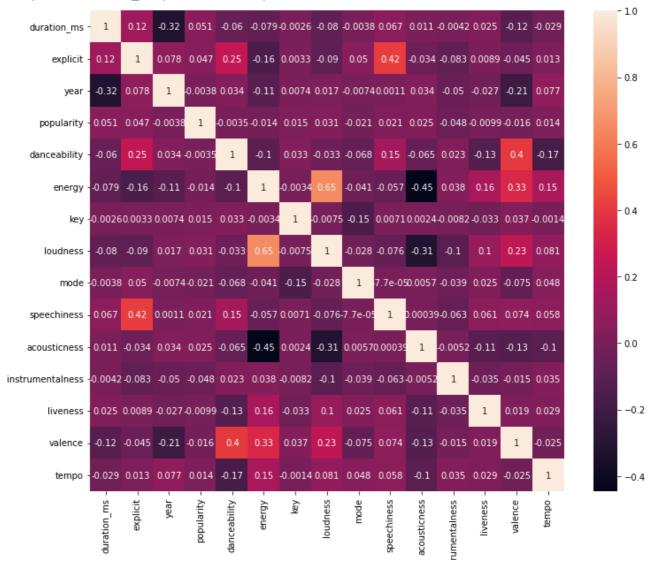
```
# Se face transformarea dataframe-ului in Pandas pentru a putea creea ploturi
```

df\_pandas = df.toPandas()

# Se afiseaza matricea de corelatii

```
plt.figure(figsize=(12,10))
sns.heatmap(df_pandas.corr(),annot=True)
```

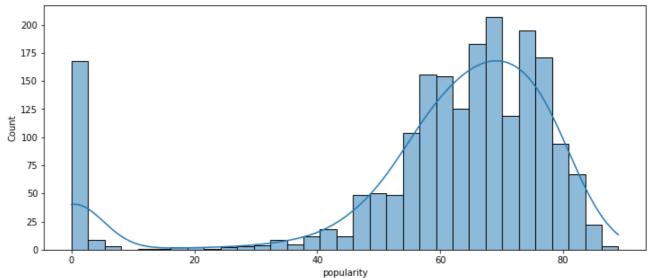
<matplotlib.axes.\_subplots.AxesSubplot at 0x7f83e8165210>

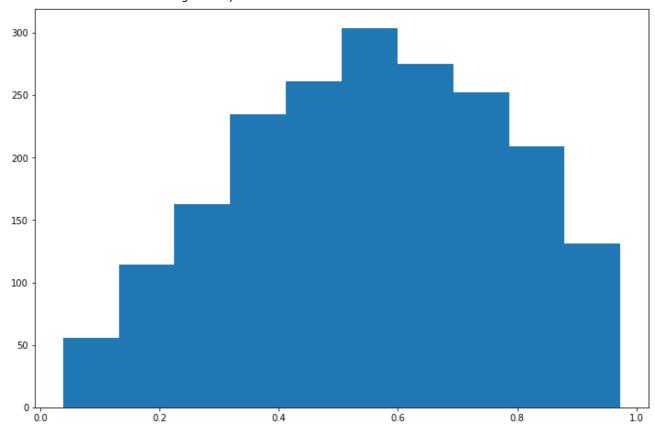


# Histograma pentru distributia coloanei 'popularity'

plt.figure(figsize=(12, 5))
sns.histplot(df\_pandas['popularity'], kde=True)

<matplotlib.axes.\_subplots.AxesSubplot at 0x7f83e515b650>





In histograma realizata pentru variabila 'valence' se poate observa ca predomina in top cantecele cu o valenta ridicata. Asa cum am scris si mai sus, la prezentarea atributelor din setul de date, o valenta crescuta indica de obicei o melodie cu un ton vesel, fericit si euforic, in timp ce o melodie cu valenta scazuta indica un cantec cu ton trist, deprimat, negativ. Deci, uitandu-ne la histograma de mai sus se poate deduce ca majoritatea hiturilor par sa fie melodii cu un ton vesel.

## 4. Verificarea si prelucrarea datelor

Se vor sterge coloanele'artist' si 'song' fiind considerate irelevante in procesul de predictie ce va urma, apoi se verifica fiecare coloana ramasa pentru a vedea daca exista valori null. De asemenea, se afiseaza valorile din coloana 'genre' si se ia o decizie asupra modului in care vor fi utilizate datele de acolo. Se va folosi StringIndexer pentru transformarea in variabila categoriala

# Se sterg coloanele 'artist' si 'song'

```
a variabilei string 'genre' si se va crea un vector denumit "features", format din coloanele
```

```
df = df.drop('artist')
df = df.drop('song')
df.columns
    ['duration_ms',
     'explicit',
     'year',
     'popularity',
     'danceability',
     'energy',
     'key',
     'loudness',
     'mode',
     'speechiness',
     'acousticness',
     'instrumentalness',
     'liveness',
     'valence',
     'tempo',
     'genre']
# Se verifica daca exista valori null si se afiseaza cate valori null sunt pentru fiecare
df_agg= df.agg(*[f.count(f.when(f.isnull(c), c)).alias(c) for c in df.columns])
df_agg.show()
    |artist|song|duration_ms|explicit|year|popularity|danceability|energy|key|loudness|mc
```

Se observa ca nu sunt valori null, deci nu trebuie sterse intrari din setul de date, sau inlocuite in vreun fel datele din coloana respectiva.

0|

0|

0|

0|

0|

```
# Se obtine numarul de valori pentru coloana genre
df2 = df.groupBy('genre').count()
df2.orderBy(col("count").desc(),col("genre").asc()).show(60)
     lbob' nauce/erecri....
                  pop, R&B
                             178
                   hip hop | 124|
     |hip hop, pop, Dan...|
                              78
                              58
                      rock
                 rock, pop
                              43
          Dance/Electronic|
                              41
               rock, metal|
                              38
                pop, latin
                              28
                 pop, rock
                              26
                     set()|
                              22
```

0|

```
|hip hop, Dance/El...|
                        16
               latin|
                        15
 hip hop, pop, latin
                        14
    pop, rock, metal
                        14
                        13
pop, rock, Dance/...
                        13
             country
                        10
  hip hop, pop, rock
                         9 |
                         9|
               metal
  pop, Folk/Acoustic|
                         8 |
        pop, country
                         8
rock, pop, Dance/...
                         8
pop, R&B, Dance/E...
                         61
    rock, pop, metal
                         4
        hip hop, R&B
                         3
|hip hop, pop, R&B...|
|hip hop, pop, R&B...|
                         3
  Folk/Acoustic, pop
                         2|
|World/Traditional...|
|World/Traditional...|
                         2
|World/Traditional...|
                         2 |
|World/Traditional...|
  hip hop, rock, pop
                         2
|pop, easy listeni...|
                         2 |
pop, rock, Folk/A...
                         2
         rock, blues
                         2
  rock, blues, latin
                         2
| Folk/Acoustic, rock|
                         1
|Folk/Acoustic, ro...|
                         11
|World/Traditional...|
|World/Traditional...|
                         1
      country, latin|
                         1|
      easy listening
                         1
    hip hop, country
                         11
|hip hop, latin, D...|
                         11
|hip hop, pop, cou...|
                         1
|pop, R&B, easy li...|
                         1
|pop, easy listeni...|
|rock, Dance/Elect...|
                         1|
|rock, Folk/Acoust...|
                         1|
rock, Folk/Acoust...|
rock, R&B, Folk/A...
                         1
     rock, classical
                         1
|rock, easy listening|
|rock, pop, metal,...|
+----+
```

Dupa cum se poate observa, exista si valori compuse in tabel, adica intrari care sunt incluse in mai mult de un gen. Avand in vedere faptul ca a doua cea mai numeroasa valoare pentru coloana gen este "hip hop, pop", adica o valoare compusa, si ca exista destul de sus in top intrari ce nu apartin doar unui gen, am ales sa pastrez datele asa, considerand intreaga grupare de mai multe genuri ca reprezentand un singur gen. De asemenea, varaibila gen fiind de tip string va trebui transformata in variabila categoriala pentru a putea fi utilizata mai departe.

```
#Se va folosi StringIndexer pentru a transformarea in variabila categoriala variabila stri
indexer = StringIndexer(inputCol="genre", outputCol="genre cat")
indexed = indexer.fit(df).transform(df)
indexed.columns
     ['artist',
      'song',
```

```
'duration_ms',
'explicit',
'year',
'popularity',
'danceability',
'energy',
'key',
'loudness',
'mode',
'speechiness',
'acousticness',
'instrumentalness',
'liveness',
'valence',
'tempo',
'genre',
'genre_cat']
```

Mai departe se va forma un vector 'features' utilizand coloanele relevante. Am ales sa includ in acesta toate atributele numerice, deoarece, conform matricei de corelatie, nu se poate spune ca existau valori ce ar fi fost mult mai reprezentative decat altele in relatie cu variabila 'popularitate'.

```
#Se va forma un vector denumit "features", format din coloanele relevante.
assembler = VectorAssembler(
  inputCols=['duration_ms',
             'explicit',
              'danceability',
             'energy',
             'key',
             'loudness',
             'mode',
             'speechiness',
             'acousticness',
             'instrumentalness',
            'liveness',
             'valence',
             'tempo',
             'genre cat'],
    outputCol="features")
output = assembler.transform(indexed)
#Se afiseaza coloanele "features" și "popularity" (primele 20)
```

output.select("features", "popularity").show()

<b>+</b>	+
features popula	rity
+	+
[211160.0,0.0,0.7	77
[167066.0,0.0,0.4	79
[250546.0,0.0,0.5	66
[224493.0,0.0,0.5	78
[200560.0,0.0,0.6	65
[253733.0,1.0,0.7	69
[284200.0,1.0,0.9	86
[258560.0,0.0,0.7	68
[271333.0,0.0,0.7	75
[307153.0,0.0,0.7	77
[238759.0,0.0,0.6]	1
[268863.0,0.0,0.7]	56
[306333.0,0.0,0.8]	55
[285960.0,0.0,0.5]	62
[294200.0,0.0,0.6]	61
[284000.0,0.0,0.7]	53
[245400.0,0.0,0.7]	64
[214883.0,0.0,0.6]	73
[285426.0,0.0,0.7]	64
[161506.0,1.0,0.9	82
+	+
only showing top 20 rows	

## ▼ 5. Alegerea si implementarea modelelor

Folosind setul de date ales, se doreste prezicerea popularitatii unor melodii in functie de anumite caracteristici. Pentru rezolvarea acesteia, se vor folosi 3 modele ML. Deoarece problema pusa de mine este una de regresie, modelele ML alese si implementate vor fi de tip regresie.

#### 1. Regresie Liniara

Primul pas va fi creeare unui data frame pentru regresie, folosid doar coloanele 'features' si 'popularity' apoi se va face o diviziune asupra setului de date. Datele din setul de date vor fi impartite in doua subseturi: unul pentru antrenarea modelului si unul pentru testarea lui, procentele utilizate la impartire fiind 70% pentru cel de antrenare si 30% pentru cel de testare. Se va creea apoi un obiect de tip Linear Regresion, se antreneaza modelul si se testeaza.

#### 2. Random Forest

Pentru acest model am ales sa creez un nou vector, numit 'features2', in care am utilizat doar variabilele 'explicit', 'danceability', 'energy', 'key', 'loudness', 'mode', 'speechiness', 'instrumentalness', 'valence' si 'tempo'. Se creeaza un data frame nou, utilizand 'popularity' si 'features2' si se imparte iarasi setul de date in date de antrenare si date de testare, folosind procentul 70% pentru datele de antrenare si 30% pentru cele de testare. Apoi se

creeaza un obiect de tip Random Forest Regressor cu coloanele 'popularity' si 'features2' si un pipeline. Se antreneaza modelul utilizand pipeline-ul creeat, apoi se testeaza si se evalueaza rezultatul obtinut.

### 3. Gradient-boosted tree regression

Pentru acest model voi folosi acelasi vectpr de features creeat la al doilea model si anume 'features2' si aceleasi seturi de date de antrenament si de testare. Prima data se creeaza un obiect de tipul GBTRegressor si un nou pipeline, apoi se antreneaza modelul folosind pipeline-ul. Se fac predictii pe baza setului de date de test, utilizand modelul antrenat si se evalueaza predictiile.

#### LINEAR REGRESSION

```
# Se creeaza un dataframe doar cu aceste 2 coloane

df_linear_regression = output.select("features", "popularity")

# Se face o diviziune a setului de date în subseturi pentru antrenare si testare testare.
trainData,testData = df_linear_regression.randomSplit([0.7,0.3])
```

#Se afiseaza statistici asupra datelor pentru training
trainData.describe().show()

+	+
summary	popularity
++	+
count	1372
mean	59.498542274052475
stddev	21.72544342726445
min	0
max	89
++	+

#Se afiseaza statistici asupra datelor pentru test
testData.describe().show()

summary  popularity ++ 628   count  628   mean 60.689490445859875   stddev 20.451149663208614   min  0	+	++	
mean 60.689490445859875 stddev 20.451149663208614	opularity	summary	
mean 60.689490445859875 stddev 20.451149663208614	+	++	
stddev 20.451149663208614	628	count	
•	445859875	mean	
min  0	663208614	stddev	
	0	min	
max  88	88	max	
+	+	++	

# Se creeaza un obiect de tip LinearRegression

```
lr = LinearRegression(labelCol='popularity')
# Se antreneaza modelul
lrModel = lr.fit(trainData)
# Se afiseaza coeficientii si interceptia pentru regresia liniara
print("Coefficients: {} Intercept: {}".format(lrModel.coefficients,lrModel.intercept))
     Coefficients: [3.939419358086384e-05,1.9804784664542867,-5.173406349284654,-10.658491
#Se evalueaza modelul pe datele de testare
results = lrModel.evaluate(testData)
# Se afiseaza informatiile obtinute dupa evaluare
print("RMSE: {}".format(results.rootMeanSquaredError))
print("MSE: {}".format(results.meanSquaredError))
print("R2: {}".format(results.r2))
     RMSE: 20.773414010086253
     MSE: 431.5347296344478
     R2: -0.033409387199559326
# Se afiseaza valorile reziduale
results.residuals.show()
                residuals
     +----+
       21.652972661839392
        25.077750980152828
      -50.910914161495775
         2.159522545542657
         21.73265916605169
      -12.356734245566123
      -50.432759355479504
        0.9846883744631043
      -14.566564619892418
        -7.801268867453686
         8.520262865642117
         4.727084495405094
      -0.14343902533298802
         7.210548252080976
        21.575182493473086
        13.648722525142482
         -7.49211244179191
        12.566787472630544
        22.444600893085067
```

# Sa se afiseze corelatia intre 'popularity' si 'speechiness'

```
from pyspark.sql.functions import corr
df.select(corr('popularity','speechiness')).show()
```

```
# Sa se afiseze corelatia intre 'popularity' si 'loudness'
from pyspark.sql.functions import corr
df.select(corr('popularity','loudness')).show()
```

#Aplicați modelul pe datele de test neetichetate
unlabeled\_data=testData.select("features")
predictions = lrModel.transform(unlabeled\_data)
predictions.show()

```
+----+
          features| prediction|
+----+
[113000.0,0.0,0.9... 54.34702733816061]
|[119133.0,1.0,0.8...| 57.92224901984717|
[129264.0,1.0,0.9...|51.910914161495775|
|[144244.0,0.0,0.8...| 54.84047745445734|
|[149546.0,1.0,0.8...| 57.26734083394831|
[150533.0,0.0,0.8... 51.35673424556612]
|[150533.0,0.0,0.8...|50.432759355479504|
|[151640.0,0.0,0.7...|60.015311625536896|
|[151973.0,0.0,0.7...| 57.56656461989242|
[156773.0,1.0,0.7...|58.801268867453686]
|[157293.0,0.0,0.4...| 57.47973713435788|
[157643.0,1.0,0.6...|58.272915504594906]
|[161240.0,0.0,0.8...| 56.14343902533299|
|[161746.0,0.0,0.7...|55.789451747919024|
[161920.0,0.0,0.4...|58.424817506526914]
[163320.0,1.0,0.8... 58.35127747485752]
|[164506.0,1.0,0.6...| 56.49211244179191|
|[165440.0,0.0,0.6...|54.433212527369456|
|[165853.0,0.0,0.6...| 55.55539910691493|
|[166373.0,1.0,0.5...| 59.07932303618398|
+----+
only showing top 20 rows
```

```
testData.show()
```

```
features|popularity|
+----+
|[113000.0,0.0,0.9...|
|[119133.0,1.0,0.8...|
                          83 l
[129264.0,1.0,0.9...]
                           1
[144244.0,0.0,0.8...]
                           57
|[149546.0,1.0,0.8...|
                           79 l
|[150533.0,0.0,0.8...|
                           39|
|[150533.0,0.0,0.8...|
                           0
|[151640.0,0.0,0.7...|
                           61 l
[151973.0,0.0,0.7...]
                           43
|[156773.0,1.0,0.7...|
                           51
[157293.0,0.0,0.4...]
                           66 l
|[157643.0,1.0,0.6...|
                           63
|[161240.0,0.0,0.8...|
                           56 l
[161746.0,0.0,0.7...]
                           63
|[161920.0,0.0,0.4...|
                           80
|[163320.0,1.0,0.8...|
                           72 l
[164506.0,1.0,0.6...]
                           49|
|[165440.0,0.0,0.6...|
                           67
|[165853.0,0.0,0.6...|
                           78 l
[166373.0,1.0,0.5...]
                           73
+----+
only showing top 20 rows
```

### **RANDOM FOREST**

```
#Se creeaza un nou vector, numit 'features2'
assembler = VectorAssembler(
  inputCols=['explicit',
             'danceability',
             'energy',
             'key',
             'loudness',
             'mode',
             'speechiness',
            'instrumentalness',
            'valence',
            'tempo'],
    outputCol="features2")
output2 = assembler.transform(indexed)
# Se creeaza un data frame nou
df RandomForest = output2.select("features2", "popularity")
# Se imparte iar setul de date in date de antrenare si date de test, cu procente 70% si 30
trainData,testData = df RandomForest.randomSplit([0.7,0.3])
```

#Se afiseaza statistici asupra datelor pentru training

```
trainData.describe().show()
```

++	+
summary	popularity
++	+
count	1389
mean 60	.0280777537797
stddev 21	.2294977374443
min	0
max	88
++	

#Se afiseaza statistici asupra datelor pentru test

testData.describe().show()

```
|summary| popularity|
|------+
| count| 611|
| mean| 59.51882160392799|
| stddev|21.588116553187866|
| min| 0|
| max| 89|
```

```
rfModel = model.stages[1]
print(rfModel)

MAE on test data = 14.8176
   RandomForestRegressionModel: uid=RandomForestRegressor_c694186409c2, numTrees=20, num
```

#### **GRADIENT-BOOSTED TREE REGRESSION**

```
# Se creeaza un obiect de tipul GBTRegressor
gbt = GBTRegressor(labelCol = 'popularity', featuresCol="indexedFeatures", maxIter=10)
#Se creeaza un pipeline nou
pipeline = Pipeline(stages=[featureIndexer, gbt])
# Se antreneaza modelul
model = pipeline.fit(trainData)
# Se fac predictiile utilizand datele de testare
predictions = model.transform(testData)
# Se evalueaza predictiile utilizand RegressionEvaluator
evaluator = RegressionEvaluator(
    labelCol="popularity", predictionCol="prediction", metricName="mae")
mae = evaluator.evaluate(predictions)
print("MAE on test data = %g" % mae)
gbtModel = model.stages[1]
print(gbtModel)
     MAE on test data = 16.8647
     GBTRegressionModel: uid=GBTRegressor e5dd1d60dec2, numTrees=10, numFeatures=10
```

### 6. Utilizarea unui model DL

Modelul DL va fi de tip regresie si va avea ca scop rezolvarea aceleiasi probleme: prezicerea popularitatii unor melodii. Pentru acesta se va folosi un data frame de tip pandas din care se va sterge variabila de tip string ('genre') si se vor separa caracteristicile variabilei tinta ('popularity'), apoi se vor imparti datele in date de antrenare si date de testare. Se va aplica un feature scaling; acesta va invata pe datele de antrenare si va fi aplicat pe datele de antrenament si de test. Apoi se va creea o retea neuronala cu o arhitectura adaptata problemelor de tip regresie si se va compila modelul, avand parametrii de pe ultimul strat luati in calcul, aceasta fiind o problema de regresie si nu de clasificare. Se antreneaza modelul pentru 200 de epoci si o dimensiune a batch-ului de 128. La final, se va folosi un grafic pentru a analiza training loss-ul si validation loss-ul si se vor afisa valorile RMSE, MAE si MSLE.

```
# Se transforma data frame-ul intr-un dat frame de tip pandas
dfdl = df.toPandas()
# Se scoate coloana 'genre'
dfdl = dfdl.drop('genre', axis = 1)
# Se separa caracteristicile variabilei 'popularity'
X = dfdl.drop('popularity', axis = 1)
y = dfdl['popularity']
# Se impart datele in date de antrenare si date de testare
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=101)
# feature scaling
scaler = MinMaxScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
# Se afiseaza forma dataset-urilor de antrenament si de testare
print(X_train.shape)
print(X_test.shape)
     (1400, 14)
     (600, 14)
# Se creeaza o retea neuronala ce are o arhitectura potrivita unei probleme de tip regresi
model = Sequential()
model.add(Dense(14, activation='relu', input_shape=(14, )))
model.add(Dense(14, activation='relu'))
model.add(Dense(14, activation='relu'))
model.add(Dense(14, activation='relu'))
model.add(Dense(1, activation='linear'))
model.summary()
```

Model: "sequential 1"

Layer (type)	Output Shape	Param #
dense_5 (Dense)	(None, 14)	210
dense_6 (Dense)	(None, 14)	210
dense_7 (Dense)	(None, 14)	210
dense_8 (Dense)	(None, 14)	210
dense_9 (Dense)	(None, 1)	15

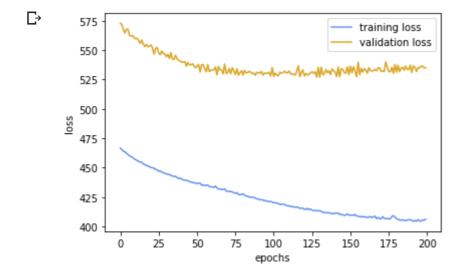
Total params: 855
Trainable params: 855

Non-trainable params: 0

```
# Se compileaza modelul
model.compile(optimizer='adam', loss='mse')
# Se antreneaza modelul pentru 200 de epoci si o dimensiune a batch-ului de 128.
history = model.fit(x=X_train,
     y=y_train,
     validation_data=(X_test, y_test),
     batch_size=128,
     epochs=200)
 Epoch 173/200
 11/11 [============== ] - 0s 6ms/step - loss: 406.8965 - val loss:
 Epoch 174/200
 Epoch 175/200
 Epoch 176/200
 Epoch 177/200
 Epoch 178/200
 Epoch 179/200
 Epoch 180/200
 Epoch 181/200
 Epoch 182/200
 Epoch 183/200
 Epoch 184/200
 Epoch 185/200
 Epoch 186/200
 11/11 [============ ] - 0s 5ms/step - loss: 405.2679 - val loss:
 Epoch 187/200
 Epoch 188/200
 Epoch 189/200
 Epoch 190/200
 Epoch 191/200
 Epoch 192/200
 Epoch 193/200
```

# Se analizeaza pe grafic training loss-ul si validation loss-ul

```
plt.plot(history.history['loss'], c='cornflowerblue', label='training loss')
plt.plot(history.history['val_loss'], c='goldenrod', label='validation loss')
plt.legend()
plt.xlabel('epochs')
plt.ylabel('loss');
```



# Calcularea si afisarea valorilor RMSE, MAE, MSLE

```
y_pred = model.predict(X_test).reshape((-1, ))

mae = mean_absolute_error(y_test, y_pred)

rmse = np.sqrt(mean_squared_error(y_test, y_pred))

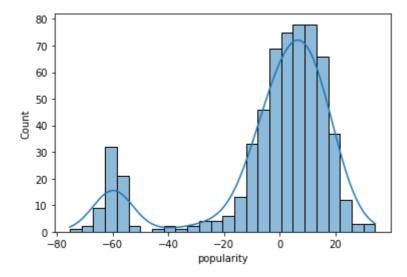
msle = mean_squared_log_error(y_test, y_pred)

print(f'RMSE: {rmse} - MAE: {mae} - MSLE: {msle}')
```

RMSE: 23.130289447348677 - MAE: 15.395006917317708 - MSLE: 1.7371994692508974

```
# Se calculeaza vectorul de valori reziduale (valori reale - predictii)
errors = y_test - y_pred
```

# Histograma cu estimarea densitatii acestor erori.
sns.histplot(x=errors, kde=True);



✓ 0s completed at 12:12 AM

×